

# 강의계획표

주	해당 장	주제
1	1장	머신러닝이란
2	2장, 3장	머신러닝을 위한 기초지식, 구현을 위한 도구
3	4장	선형 회귀로 이해하는 지도학습
4	5장	분류와 군집화로 이해하는 지도 학습과 비지도 학습
5	6장	다양한 머신러닝 기법들
6		- 다항 회귀, Logistic Regression
7		- 정보이론, 결정트리 - SVM, Ensemble
8		중간고사 (04-20)
9	7장	인공 신경망 기초 - 문제와 돌파구
10	8장	고급 인공 신경망 구현
11	9장	신경망 부흥의 시작, 합성곱 신경망
12	10장	순환 신경망
13	11장	차원축소와 매니폴드 학습
14	<b>12장 보강주</b>	<b>오토인코더와 잠재표현 학습 AI의 현재와 미래</b>
15		
16		기말고사

# **12장 오토인코더와 잠재 표현 학습**

**14 주차**

- 신경망을 통해 데이터의 특징을 찾아내는 방법
- 데이터의 특징을 유지한 잠재표현으로 바꾸고 원 데이터를 복원하는 모델
- 오토인코드를 통한 특징 추출
- 잠재표현과 오토인코드를 통한 차원축소와 복원
- 잠재표현을 이용한 새로운 데이터 생성 방법
  
- 참고문헌
  - [\[정리노트\] \[AutoEncoder의 모든것\] Chap3. AutoEncoder란 ...](#)
  - [08. 오토인코더 \(AutoEncoder\)](#)
  - [AutoEncoder\(오토인코더\) - MNIST dataset 사용 - 별준 코딩](#)
  - [케라스로 이해하는 Autoencoder | Keras for Everyone](#)

# 특징, 그리고 잠재 표현 학습 (1)

## ❖ 차원 축소 dimensionality reduction

- 데이터를 표현하기 위해 사용하는 공간을 더 낮은 차원으로 바꾸는 것
- 차원의 저주를 피함
- CNN은 합성곱 계층과 풀링 계층을 거치면서 불필요한 정보는 제거불필요한 정보는 제거하고 필요한 **특징을 추출**하여 낮은 차원에 표현

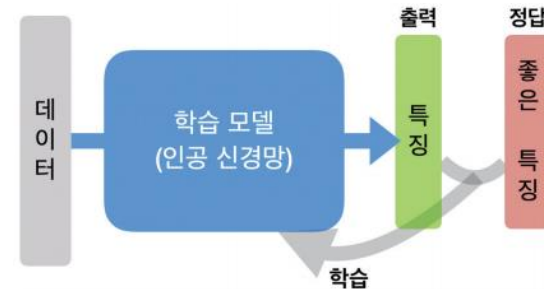
## ❖ 특징 추출

- 차원 축소와 원래 데이터를 다른 공간으로 옮기는 것
- 데이터를 다른 방식으로 표현(예, SVD: 데이터의 압축과 복원)
  - 데이터를 압축해서 얻은 정보는 원래 이미지에서 발견할 수 있는 특성이 전혀 없어 보임
  - 복원 연산을 통해 정보가 다 사라진 것처럼 보였던 압축 데이터에서 원래 이미지의 모습을 다시 생성
  - 압축 데이터는 우리가 눈으로 관찰하는 것과는 전혀 다른 방식으로 데이터를 표현하는 것으로, 원래의 데이터가 가진 특징을 잃어버리지 않아 복원 과정에서 원래의 데이터를 더 잘 재현
- LLE, Isomap, t-SNE

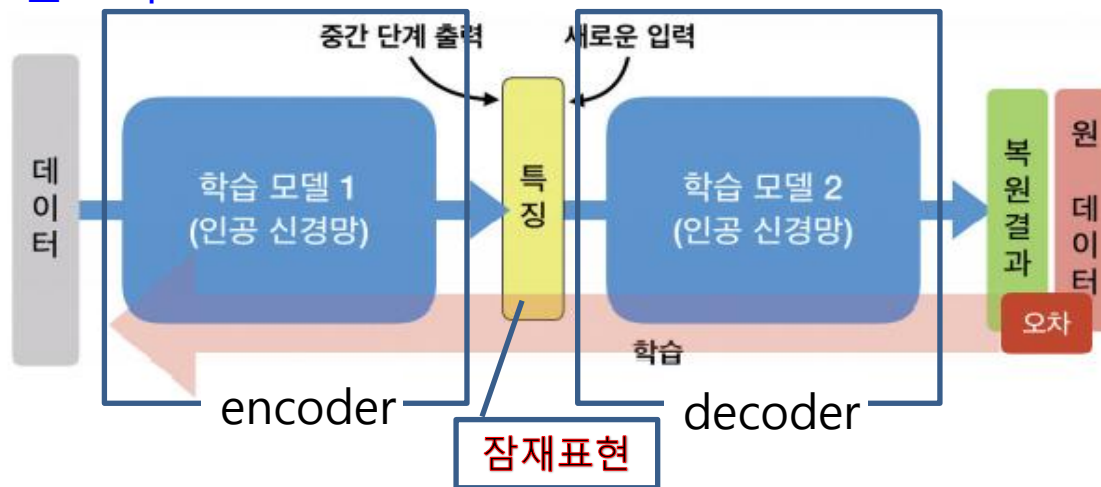
# 특징, 그리고 잠재 표현 학습 (2)

## ❖ 인공지능망을 이용한 특징 추출

- 정답으로 **좋은 특징(?)**을 제공
- 출력과 비교하여 학습



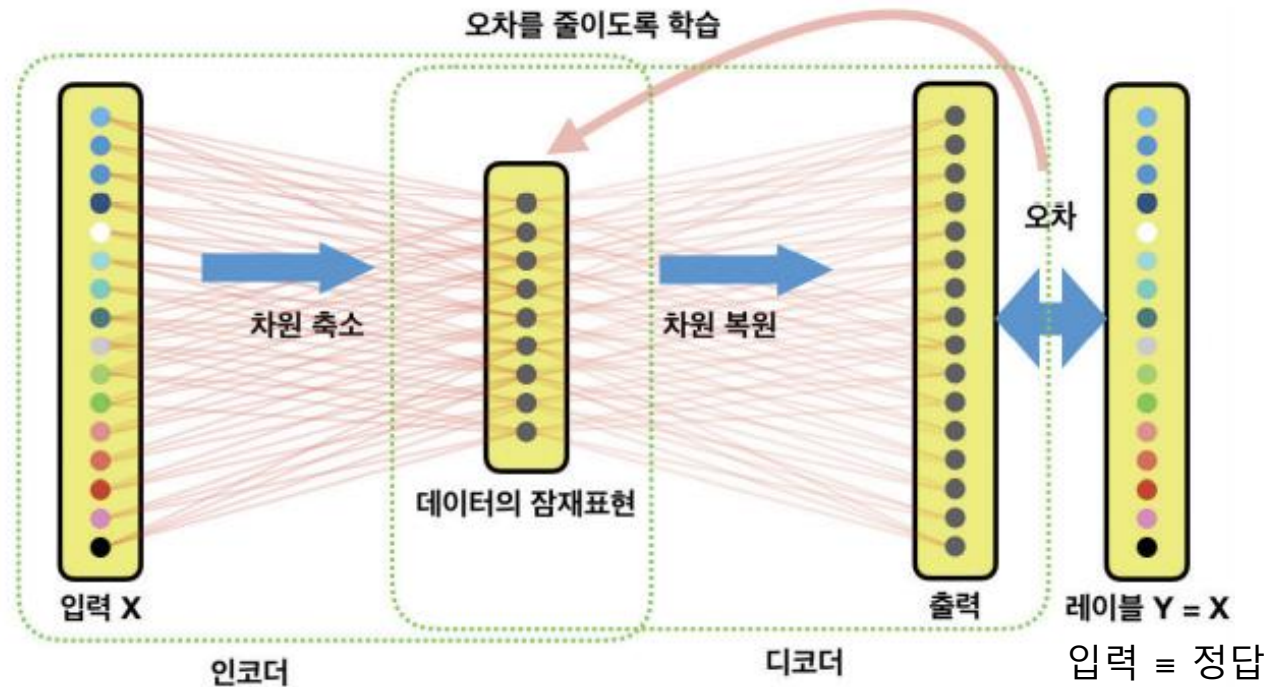
## ❖ 오토인코더 autoencoder



- 입력 데이터를 우리가 관심을 가지는 데이터 공간의 일부만을 제한적으로 드러내는 표본이라고 할 때, 이 데이터를 포함하는 미지의 큰 데이터 집단은 어떤 특징을 가지는지 파악하기 위해 사용할 수도 있을 것
- **잠재 표현** latent representation : 데이터를 잠재공간(**중간 단계의 특징표현 공간**)에 표현
- **오토인코더**: 입력 데이터의 **분포를 학습**하여 얻은 잠재 표현을 이용하여 다양한 분야, 특히 데이터를 생성하는 모델

# 압축과 복원 - 오토인코더로 구현하기 (1)

## ❖ Autoencoder의 신경망 구현



- 잠재 표현은 입력 데이터를 잘 표현하는 특징
- 사람의 개입 없이 특징을 추출하는 역할
- 차원 축소 기법을 통해 얻는 것이 아니라, 신경망이 자동으로 생성한 모델을 통해 얻음

# 압축과 복원 - 오토인코더로 구현하기 (2)

## ❖ Keras API

```
encoding_layers = Sequential(...  
decoding_layers = Sequential(...
```

← decoding\_layers는 encoding\_layers의  
출력을 입력으로 사용


```
AE = Sequential([encoding_layers, decoding_layers])
```

```
AE.fit(X, X, epoch = n_epoch)
```

← 학습: 입력과 출력이 같음

```
embedding = encoding_layers.predict(X)
```

← 잠재표현



# Program (1)

## ❖ LAB<sup>12-1</sup> 오토인코더로 롤 모양의 데이터응 2차원 공간에 임베딩

- <https://colab.research.google.com/drive/1rCWIRCOELejbUEKIX0YLp8bDWDoBMn8b>
- 비교: 11장 차원 축소 결과



```
from tensorflow.keras import models
from tensorflow.keras import layers
enc = models.Sequential([layers.Dense(2, input_shape=[3],
                                     activation = 'elu')])
dec = models.Sequential([layers.Dense(3, input_shape=[2],
                                     activation = 'elu')])
```

```
AE = models.Sequential([enc, dec])
AE.compile(loss = 'mse')
AE.summary()
```

Model: "sequential\_2"

Layer (type)	Output Shape	Param #
sequential (Sequential)	(None, 2)	8
sequential_1 (Sequential)	(None, 3)	9

Total params: 17  
Trainable params: 17  
Non-trainable params: 0





# Program (2)

## ❖ LAB<sup>12-2</sup> 다층 구조 오토인코더로 차원 축소/복원

```
from tensorflow.keras import models
from tensorflow.keras import layers


enc = models.Sequential([layers.Dense(2, input_shape=[3],
                                     activation='elu'),
                        layers.Dense(2, activation='elu'),
                        layers.Dense(2, activation='elu')])
dec = models.Sequential([layers.Dense(2, input_shape=[2],
                                     activation='elu'),
                        layers.Dense(2, activation='elu'),
                        layers.Dense(3, activation='elu')])
```

```
AE = models.Sequential([enc, dec])
AE.compile(loss = 'mse')
AE.summary()
```


Model: "sequential\_4"

Layer (type)	Output Shape	Param #
sequential_2 (Sequential)	(None, 2)	20
sequential_3 (Sequential)	(None, 3)	21

```
=====
Total params: 41
Trainable params: 41
Non-trainable params: 0
=====
```



reduced = enc.predict(X)



rcvrd = dec.predict(reduced)

# Program (3)

❖ LAB<sup>12-3</sup> 오토인코더를 이용한 이미지 압축과 복원 (비교 11장 LAB<sup>11-2</sup>)

- MLP

```
from tensorflow.keras import models
from tensorflow.keras import layers

enc = models.Sequential([layers.Dense(64, input_shape=(784, ),
                                   activation='elu'),
                        layers.Dense(64, activation='elu'),
                        layers.Dense(64, activation='elu')])
dec = models.Sequential([layers.Dense(64, input_shape=(64, ),
                                   activation='elu'),
                        layers.Dense(64, activation='elu'),
                        layers.Dense(784, activation='elu')])
```

```
AE = models.Sequential([enc, dec])
AE.compile(loss = 'mse')
AE.summary()
```

Model: "sequential\_13"


Layer (type)	Output Shape	Param #
sequential_11 (Sequential)	(None, 64)	58560
sequential_12 (Sequential)	(None, 784)	59280

=====

Total params: 117,840  
Trainable params: 117,840  
Non-trainable params: 0



28x28



잠재표현  
8x8



# Program (4)

❖ LAB<sup>12-3</sup> 오토인코더를 이용한 이미지 압축과 복원 (비교 11장 LAB<sup>11-2</sup>)

- Con2D 사용

```
enc_cnn = models.Sequential([
    layers.Conv2D(filters=16, kernel_size=3,
                  activation='elu', input_shape=(28,28,1)),
    layers.Conv2D(filters=16, kernel_size=3, activation='elu'),
    layers.Flatten(),
    layers.Dense(64, activation='elu')])

dec_cnn = models.Sequential([
    layers.Dense(9216, input_shape=(64, ), activation='elu'),
    layers.Reshape(target_shape=(24,24,16)),
    layers.Conv2DTranspose(filters=16, kernel_size=3, activation='elu'),
    layers.Conv2DTranspose(filters=1, kernel_size=3, activation='elu')])
```



원본

```
samples = samples.reshape(-1, 28, 28, 1)
reduced = enc_cnn.predict(samples)
recovered = dec_cnn.predict(reduced)
plot_images(5, 10, recovered.reshape(-1, 28, 28))
```

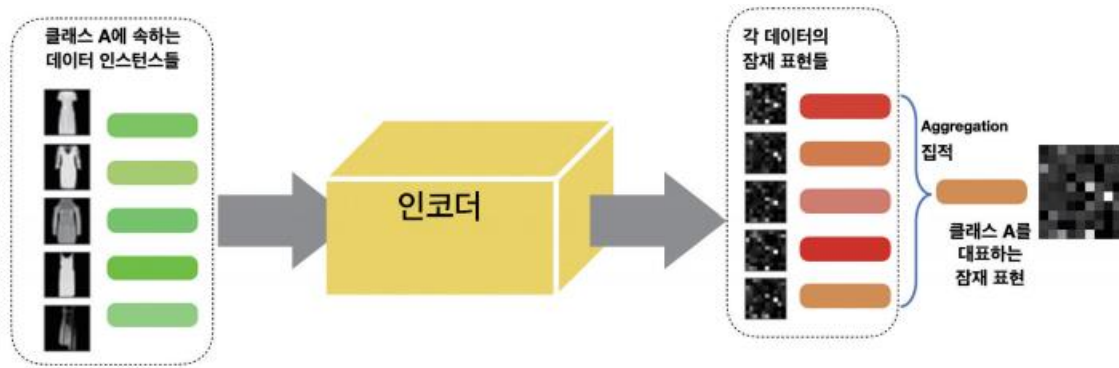
복원



# 잠재 표현으로 새로운 데이터 만들기 (1)

## ❖ 클래스 대표 데이터 생성기

- 학습이 끝난 뒤에, 같은 클래스에 속하는 데이터들만 인코더를 통과시키면 해당 클래스에 속한 데이터들의 잠재 표현을 얻을 수 있음
- **집적화**aggregation 연산: 평균값을 구하는 연산



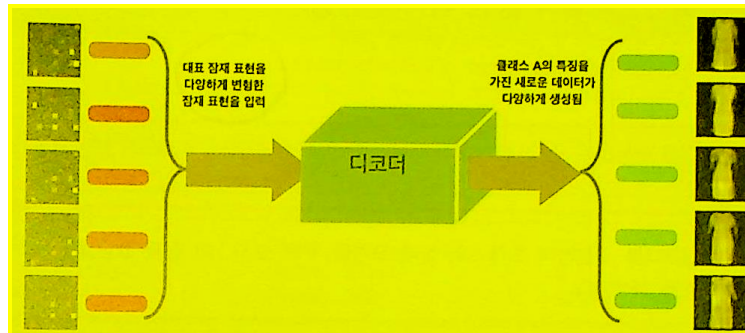
- 대표 잠재 표현을 입력받은 디코더는 해당 클래스의 특징을 가장 잘 드러내는 새로운 이상적인 데이터를 만들어 냄



# 잠재 표현으로 새로운 데이터 만들기 (2)

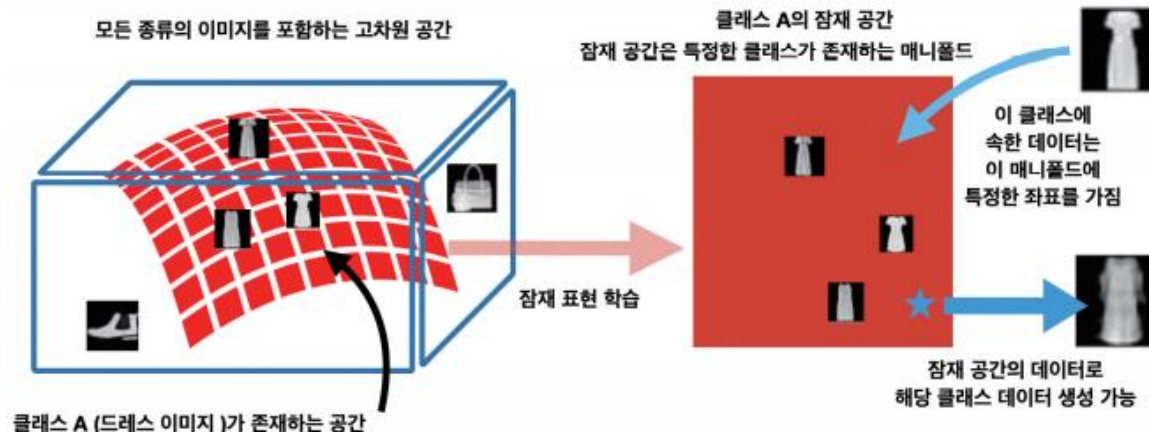
## ❖ 클래스에 속하는 다양한 데이터 생성기

- 대표 잠재 표현을 조금씩 변형하여 디코더에 입력
- 클래스의 특징은 가지고 있지만 원래의 데이터에서 관찰할 수 없었던 새로운 데이터를 얻을 수 있음



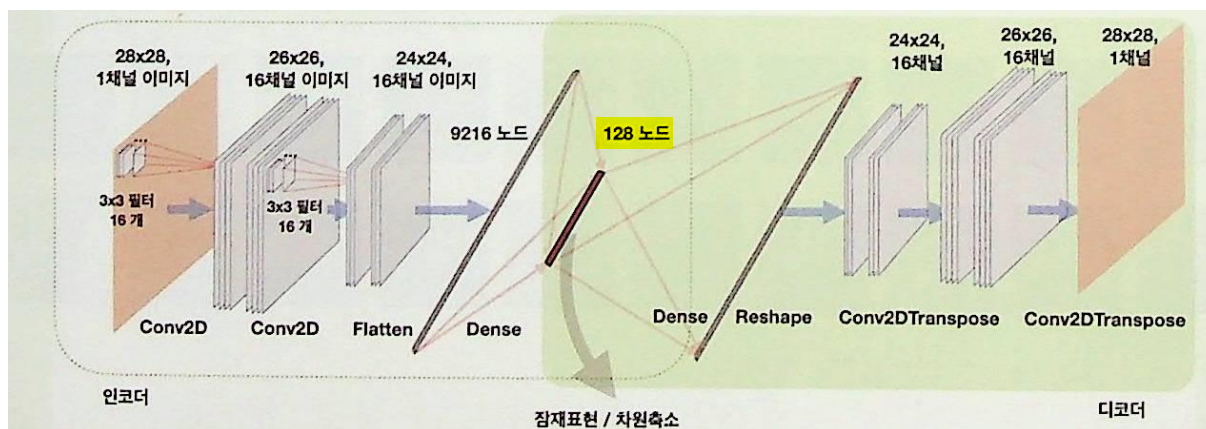
## ❖ 잠재공간의 학습

- 관찰한 데이터의 본질적 모습을 찾는 작업



# Program (5)

## ❖ LAB<sup>12-4</sup> 오토인코더를 이용한 데이터 생성



```
enc_cnn = models.Sequential([
    layers.Conv2D(filters=16, kernel_size=3,
                  activation='elu', input_shape=(28,28,1)),
    layers.Conv2D(filters=16, kernel_size=3, activation='elu'),
    layers.Flatten(),
    layers.Dense(100, activation='elu')])
enc_cnn.summary()
```

Model: "sequential"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 26, 26, 16)	160
conv2d_1 (Conv2D)	(None, 24, 24, 16)	2320
flatten (Flatten)	(None, 9216)	0
dense (Dense)	(None, 100)	921700

```
dec_cnn = models.Sequential([
    layers.Dense(9216, input_shape=(100, ), activation='elu'),
    layers.Reshape(target_shape=(24,24,16)),
    layers.Conv2DTranspose(filters=16, kernel_size=3, activation='elu'),
    layers.Conv2DTranspose(filters=1, kernel_size=3, activation='elu')])
dec_cnn.summary()
```

Model: "sequential\_1"


Layer (type)	Output Shape	Param #
dense_1 (Dense)	(None, 9216)	930816
reshape (Reshape)	(None, 24, 24, 16)	0
conv2d_transpose (Conv2DTran	(None, 26, 26, 16)	2320
conv2d_transpose_1 (Conv2DTr	(None, 28, 28, 1)	145



# Program (5)




Train\_labels = 3



Train\_labels 3의 잠재표현

Train\_labels 3의  
대표 잠재표현



dress\_latent =  
dress\_encoded.mean(axis = 0)



dress\_generated = dec\_cnn.predict([dress\_latent\_augmented])

# Mini Project (잡음제거)

## ❖ A2 잡음제거: 오토인코더 활용(비교 A1 k-NN의 활용)


- <https://colab.research.google.com/drive/1cifkeX53mLnYdyv2yeLj02SmtR3GtMkc>
- 잠재표현: 잡음과 같이 중요하지 않는 데이터 제거한 것




원본에 noise 추가

```
enc_cnn = models.Sequential([
    layers.Conv2D(filters=16, kernel_size=3,
                  strides=(3,3), activation='elu', input_shape=(63,63,3)),
    layers.Conv2D(filters=8, kernel_size=3, activation='elu'),
    layers.Flatten(),
    layers.Dense(1024, activation='elu')])

dec_cnn = models.Sequential([
    layers.Dense(2888, input_shape=(1024, ), activation='elu'),
    layers.Reshape(target_shape=(19,19,8)),
    layers.Conv2DTranspose(filters=16, kernel_size=3, activation='elu'),
    layers.Conv2DTranspose(filters=3, kernel_size=3, strides=(3,3),
                           activation='elu')])
```



Train data의 잠재표현



Test data의 잠재표현  
Data 부족




# Mini Project (잡음제거)

## ❖ Data 증강

- `keras.preprocessing.image.ImageDataGenerator` class
- 새로운 image 생성: `ImageDataGenerator.flow()`
- 새로운 image에 잡음 추가: `new_y + np.random.randn(nData, imgR, imgC, channel)*0.3`


```
from keras.preprocessing.image import ImageDataGenerator
image_generator = ImageDataGenerator(
    rotation_range=360,
    zoom_range=0.1,
    shear_range=0.1,
    width_shift_range=0.1,
    height_shift_range=0.1,
    horizontal_flip=True,
    vertical_flip=True)
```



변형된 image



변형된 image에 noise 추가



Test data의 잠재표현

# Mini Project (데이터 분포 visualization)

## ❖ C1 차원축소: 데이터 분포 가시화

- Autoencoder를 사용한 잠재표현(128차원)
- T-SNE

